

Lista 1 – TP555/AI-ML

1 - a) Inteligência

R: Capacidade de adquirir e aplicar conhecimentos e habilidades para resolver problemas, adaptar-se a novas situações, compreender e processar informações, e tomar decisões com base na razão e na experiência.

b) Inteligência Artificial

R: É o campo da computação que criar máquinas que tenta imitar a capacidades humanas. Tomar decisões e resolver problemas, interagindo com o ambiente.

c) Aprendizado de Máquina

R: É uma das subáreas da Inteligência Artificial, aprende sem serem explicitamente programadas.

2 - Resposta: Letra A

3 - T -> Prever o clima com base nos dados

E-> Conjunto de dados climáticos usados para treinar o modelo.

4 - Problema de Classificação, pois o objetivo é atribuir um dos três rótulo a cada dia.

5 - Para determinar ações seria certo usar regressão, pois estamos tentando prever um valor contínuo.

6 - Aprendizado por reforço, o sistema é treinado e, a partir de recompensas positivas ou negativas (como a penalidade) aprimora a sua aprendizagem por reforço. Por exemplo se a exploração do robô é correta ele ganha “recompensas” e se não for é dado penalidades.

7- a) Usaria classificação supervisionada: Árvore de decisão, K-Nearest Neighbors (KNN), Random Forest etc. Como já existem os rótulos, o modelo pode ser treinado com dados rotulados e, depois, classificar novos clientes nos grupos adequados.

b) Aprendizado Não-Supervisionado (Clusterização): K-Means, Kernel PCA. O modelo analisará padrões nos dados e formará grupos com base em similaridades, sem precisar de rótulos prévios.

8 - Problema de Classificação, a modulação transmite dados usando quatro símbolos distintos, como a saída esperada é um rótulo discreto e não um valor contínuo, trata-se de um problema de classificação e não regressão

9 - Batelada:

Vantagens -> Eficiência computacional, Estabilidade na convergência, pode ser otimizado para hardware especializado.

Desvantagens -> Alto consumo de memória, Menor atualização dos pesos.

Mini-Batch:

Vantagens -> Eficiência e Estabilidade, Uso eficiente do hardware, Atualizações mais frequentes.

Desvantagens -> Oscilação do gradiente, Escolha do tamanho do mini-batch (escolher um tamanho inadequado pode impactar negativamente o desempenho e a precisão do modelo).

10 – a) Método: Aprendizado por Reforço Profundo (Deep Reinforcement Learning - DRL), Algoritmos Genéticos, Programação Linear.

Solução: Modelos aprendem a alocar espectro, potência e tempo de transmissão otimizando throughput e latência.

b) Método: Aprendizado por Reforço, Redes Neurais, Modelos Estatísticos (ALOHA otimizado, CSMA/CA).

Solução: Modelos ajustam políticas de acesso ao meio para minimizar colisões e melhorar eficiência da rede.

c) Método: Redes Neurais Profundas, Otimização por Evolução Diferencial, Aprendizado Supervisionado.

Solução: O modelo aprende quais esquemas de modulação e codificação maximizam a taxa de dados e minimizam erros sob diferentes condições de canal.

d) Método: Redes Neurais Convolucionais (CNN), LSTM, Aprendizado por Reforço.

Solução: Modelos detectam espectro disponível e otimizam a alocação dinâmica para redes de rádio cognitivo.

e) Método: Aprendizado Supervisionado (Random Forest, Redes Neurais), Filtragem de Partículas, Fusão de Sensores.

Solução: Algoritmos combinam sinais Wi-Fi, Bluetooth e IMU para estimar posição com precisão submétrica.

f) Método: Algoritmos de Caminho Mínimo (Dijkstra, A*), Aprendizado por Reforço, Redes Neurais.

Solução: Modelos aprendem a otimizar rotas para reduzir latência e congestionamento.

g) Método: Redes Neurais Recorrentes (RNN), Filtros Adaptativos, Algoritmos Bayesianos.

Solução: Modelos estimam a resposta do canal óptico e corrigem distorções para melhorar a qualidade do sinal recebido.

h) Método: Redes Neurais Profundas, Regressão Não-Linear, Algoritmos de Ajuste de Parâmetros.

Solução: Modelos aprendem a compensar não-linearidades de amplificadores para minimizar distorções no sinal transmitido.

I) Método: Redes Adversárias Generativas (GANs), Anomalia Detection, Machine Learning para Intrusion Detection Systems (IDS).

Solução: Modelos detectam ataques como jamming, spoofing e ataques de injeção, garantindo segurança e confiabilidade da rede.

j) Método: Redes Neurais Convolucionais (CNN), Aprendizado Supervisionado.

Solução: Modelos analisam padrões de obstrução (como edifícios e mobilidade) para prever bloqueios e ajustar a alocação dinâmica de recursos.

k) Método: Redes Neurais Profundas, Modelos de Correção de Distorção, Equalização Digital.

Solução: Modelos corrigem efeitos não-lineares em sinais ópticos para aumentar a eficiência espectral.

l) Método: Aprendizado por Reforço, Otimização de Parâmetros com Algoritmos Evolutivos.

Solução: Algoritmos ajustam dinamicamente largura de banda, modulação e potência de sinal para otimizar a eficiência da rede.

11- O sensoriamento espectral permite a detecção dinâmica do uso do espectro eletromagnético, e técnicas de Machine Learning (ML), como redes neurais convolucionais (CNNs) e redes recorrentes (LSTMs), podem ser aplicadas para identificar padrões de ocupação e melhorar a eficiência da alocação de frequências em redes cognitivas.

K. M. Thilina, K. W. Choi, N. Saquib and E. Hossain, "Machine Learning Techniques for Cooperative Spectrum Sensing in Cognitive Radio

Networks," in IEEE Journal on Selected Areas in Communications, vol. 31, no. 11, pp. 2209-2221, November 2013, doi: 10.1109/JSAC.2013.131120.

keywords: {Vectors;Training;Cascading style sheets;Energy states;Sensors;Availability;Support vector machines;Cognitive radio;cooperative spectrum sensing;K-means clustering;GMM;support vector machine (SVM);K-nearest-neighbor;primary user detection},