

Aplicação de Técnicas de Clusterização para Otimização de Energia em Ambientes IoT com Transferência Massiva de Energia Sem Fio (mWET)

Ana Cecilia Silveira Fernandes & Pedro Guilherme Fernandes Oliveira

Abstract— The rapid proliferation of Internet of Things (IoT) devices has created the need for efficient and scalable energy-delivery systems, especially when manual battery replacement is not viable. In this work, we propose a framework that integrates a wireless energy transfer (WET) model with three clustering techniques—K-Means, hierarchical clustering (Ward), and DBSCAN—to optimize the placement and movement of mobile Power Beacons (PBs) equipped with a Uniform Linear Array (ULA) using analog beamforming. First, we generate channel coefficients between PBs and IoT devices under a Rayleigh fading assumption, enabling calculation of the expected received power at each node. Next, devices are reordered by Euclidean distance and grouped into clusters using the three methods: K-Means (Silhouette Score = 0.430), Ward’s hierarchical clustering (Silhouette Score = 0.377), and DBSCAN (Silhouette Score = 0.752). Performance evaluation shows that clustering increases total transferred energy by up to $2.45\times$ relative to no clustering (compared to $2.30\times$ with K-Means and $1.45\times$ with hierarchical clustering), while reducing PB travel distance and improving overall charging efficiency in large-scale IoT deployments.

Index Terms— Internet of Things; Machine Learning; Wireless Energy Transfer; Power Beacons; Energy Optimization; Unsupervised Learning; Clustering; K-means; DBSCAN; Hierarchical Clustering; Silhouette Score; Beamforming.

Resumo— A rápida proliferação de dispositivos da Internet das Coisas (IoT) criou a necessidade de sistemas de fornecimento de energia eficientes e escaláveis, sobretudo quando a troca manual de baterias não é viável. Neste trabalho, propomos um framework que integra um modelo de transferência de energia sem fio (WET) com três técnicas de clusterização — K-Means, agrupamento hierárquico (Ward) e DBSCAN — para otimizar o posicionamento e o deslocamento de Power Beacons (PBs) móveis equipados com um Array Linear Uniforme (ULA) usando beamforming analógico. Primeiramente, geramos coeficientes de canal entre PBs e dispositivos IoT sob suposição de desvanecimento Rayleigh, permitindo calcular a potência esperada recebida em cada nó. Em seguida, os dispositivos são reordenados por distância euclidiana e agrupados em clusters utilizando os três métodos: K-Means (Silhouette Score = 0,430), agrupamento hierárquico de Ward (Silhouette Score =

0,377) e DBSCAN (Silhouette Score = 0,752). A comparação de desempenho revelou que essas técnicas aumentam a energia total transferida em até $2,45\times$ em relação ao sistema sem clusterização ($2,30\times$ com K-Means e $1,45\times$ com hierárquico), além de reduzir a distância percorrida pelos PBs e melhorar a eficiência geral de carregamento em implantações IoT de grande escala.

Palavras Chave— Internet das Coisas; Aprendizado de Máquina; Transferência de Energia Sem Fio; Beacons de Energia; Otimização de Energia; Aprendizado Não Supervisionado; Clusterização; K-means; DBSCAN; Clusterização Hierárquica; Índice de Silhueta; Formação de Feixe.

I. INTRODUÇÃO

A crescente demanda por dispositivos conectados em ambientes IoT (do inglês *Internet of Things*) e a busca por soluções energéticas sustentáveis no contexto da era 6G têm motivado estudos sobre estratégias inteligentes de fornecimento de energia [1]. A disseminação acelerada desses dispositivos - cada vez menores e mais acessíveis - projeta cenários desafiadores para a conectividade massiva que se espera na era 6G. Estima-se que até 2030 haverá cerca de 71 bilhões de dispositivos conectados em todo o mundo[2]. Por serem portáteis e oferecerem vasta gama de funcionalidades, esses nós alimentados por baterias tornam-se predominantes na tecnologia atual, o que reforça a necessidade de soluções de recarga sem fio eficientes e escaláveis.

O tempo de vida das baterias tem se mostrado um fator crítico no projeto e desenvolvimento de dispositivos IoT, particularmente quando implantados em regiões remotas e/ou de difícil acesso. Um dispositivo IoT com tempo de vida de bateria curto requer manutenção frequente, o que pode significar um aumento significativo no custo total de propriedade (TOC, do inglês *Total Ownership Cost*) [3]. Além disso, o crescimento exponencial dessas redes gera um volume expressivo de resíduos de baterias, frequentemente descartados de forma inadequada e configurando séria ameaça ambiental. É proposto soluções de *energy harvesting* e fabricação eco-friendly para minimizar esse impacto [4].

Para enfrentar esses desafios, a comunidade científica e a indústria têm investido em tecnologias de Transferência de Energia Sem Fio (WET, do inglês *Wireless Energy Transfer*), que permitem recarregar dispositivos IoT sem a necessidade de cabos. A tecnologia WET oferece diversas vantagens: (i) elimina

This project explores the use of clustering techniques to optimize energy distribution in Internet of Things (IoT) environments, with a focus on Massive Wireless Energy Transfer (mWET). By grouping IoT devices based on consumption patterns and spatial characteristics, the proposed approach aims to improve the efficiency of wireless energy allocation, reduce energy waste, and support the sustainability of next-generation networks such as 6G.

TABELA I
LISTA DE SIGLAS E SÍMBOLOS.

Sigla	Significado
IoT	<i>Internet of Things</i>
EH	<i>Energy Harvesting</i>
PB	<i>Power Beacons</i>
ML	<i>Machine Learning</i>
ULA	<i>Uniform Linear Array</i>
PCA	<i>Principal Component Analysis</i>
WET	<i>Wireless Energy Transfer</i>
mWET	<i>Massive Wireless Energy Transfer</i>

a troca constante de baterias, (ii) viabiliza operações de dispositivos "sem bateria", e (iii) permite *designs* mais robustos e compactos. Contudo, a eficiência de um sistema WET depende do posicionamento estratégico dos *Power Beacons* (PBs), responsáveis por irradiar energia sem fio. A determinação dessas posições é um desafio complexo, pois envolve fatores, como topologia do ambiente, a distância entre PBs e sensores, a atenuação do sinal, e o perfil de consumo energético de cada dispositivo. [1].

Visando otimizar tanto a localização dos PBs quanto a ordem de recarga dos nós, este trabalho propõe o uso de técnicas de clusterização para agrupar sensores segundo suas coordenadas e demandas energéticas. A partir desses grupos, definimos centróides para posicionar os PBs e estabelecemos uma sequência de carregamento que prioriza clusters com maior demanda agregada e dispositivos mais próximos ao transmissor. Técnicas como *K-Means*, *DBSCAN* e *Agglomerative Clustering* são avaliadas nesse contexto, considerando métricas de desempenho energético e escalabilidade. Estudos anteriores indicam que esses métodos podem reduzir significativamente a perda de energia e melhorar a cobertura de carregamento sem fio em redes densas de sensores [5].

Assim, as principais contribuições deste trabalho são: (i) Proposição de uma abordagem de clusterização para otimização energética em sistemas IoT com mWET; (ii) Comparação de algoritmos de clusterização (*K-Means*, *DBSCAN* e *Agglomerative Clustering*) quanto à eficiência na cobertura e distribuição de Power Beacons; (iii) Avaliação do impacto da clusterização no aumento da energia coletada pelos dispositivos em cenários simulados.

Este artigo está organizado da seguinte forma. Na Seção 2, são apresentados os fundamentos e desafios do WET em ambientes IoT. A Seção 3 introduz os conceitos de Aprendizagem de Máquina e detalha as técnicas de clusterização — *K-Means*, *DBSCAN* e Hierárquica Aglomerativa — empregadas neste trabalho. Na Seção 4, descreve-se o Modelo Proposto para posicionamento de Power Beacons móveis, enquanto a Seção 5 detalha a Solução Implementada, incluindo geração de dados sintéticos e parâmetros de simulação. Os resultados obtidos são discutidos na Seção 6, com análise quantitativa dos desempenhos de cada técnica de clustering. Por fim, a Seção 7 apresenta as Conclusões e perspectivas de trabalhos futuros.

II. TRANSFERÊNCIA DE ENERGIA SEM FIO

Esta seção apresenta os principais conceitos necessários para o desenvolvimento deste trabalho. Inicialmente, são abordados os fundamentos de IoT e WET, com ênfase nos desafios relacionados ao fornecimento eficiente de energia para dispositivos distribuídos. Em seguida, são descritos os principais métodos de clusterização utilizados para agrupar dispositivos IoT com base em critérios como localização e demanda energética. Por fim, discute-se como tais técnicas podem ser aplicadas para otimizar o posicionamento de PBs em cenários de mWET.

A. Transferência de Energia Sem Fio

O crescimento exponencial de IoT tem impulsionado o desenvolvimento de soluções energéticas inovadoras, especialmente em cenários com grande número de dispositivos distribuídos, como áreas urbanas densas e regiões rurais remotas. Nesses contextos, o uso de baterias tradicionais apresenta limitações, principalmente devido à necessidade de manutenção frequente e à dificuldade de reposição em locais de difícil acesso.[1]

Uma das abordagens mais promissoras para superar essas limitações é o WET, que permite alimentar dispositivos sem a necessidade de conexões físicas. Essa tecnologia é fundamental para garantir a autonomia energética de sensores IoT, reduzindo o descarte de baterias e contribuindo para a sustentabilidade dos sistemas.[1]. Dentro dos sistemas WET, destaca-se o conceito de *Energy Harvesting* (EH), que consiste na captação de energia do ambiente, como luz solar, vibrações mecânicas, ondas sonoras, calor e até mesmo sinais de radiofrequência. Essa abordagem pode ser classificada em dois tipos principais: *EH Ambiental*, que utiliza fontes naturais e imprevisíveis, e *EH Dedicada*, que se baseia em transmissores específicos de energia. [6]

No contexto deste trabalho, a WET com EH dedicada ganha destaque, especialmente pela possibilidade de utilização de PBs estrategicamente posicionados para maximizar a energia transferida aos dispositivos. No entanto, definir a melhor posição desses PBs é um desafio logístico e técnico, que depende da localização dos dispositivos, do perfil de consumo e de características do ambiente físico.

Dessa forma, o uso de técnicas de clusterização mostra-se adequado, pois permite identificar agrupamentos de dispositivos com necessidades energéticas semelhantes. A partir dessa divisão inteligente, é possível planejar a alocação e movimentação dos PBs, melhorando a eficiência da transferência de energia sem fio e reduzindo o número de zonas de sombra ou subatendimento energético.

B. Aplicações de Sistemas WET em IoT

A aplicação de sistemas do WET em ambientes IoT tem ganhado destaque em diversos setores verticais, como Cidades Inteligentes, Agricultura de Precisão e domótica. Nessas áreas, a capacidade de fornecer energia contínua a sensores e dispositivos, sem necessidade de cabeamento ou trocas frequentes de baterias, representa um avanço significativo tanto do ponto de vista tecnológico quanto ambiental. Em ambientes urbanos inteligentes, por exemplo, sistemas WET podem ser utilizados

Application of Wireless Energy Transfer Systems in IoT.




Fig. 1. Aplicações WET.

para alimentar sensores de tráfego, iluminação pública inteligente e estações meteorológicas urbanas, garantindo sua operação ininterrupta. Já na agricultura, a possibilidade de manter ativos sensores de umidade, temperatura e nutrientes em regiões extensas e de difícil acesso reduz custos operacionais e aumenta a eficiência na gestão de recursos naturais. [7]

Além disso, drones e veículos autônomos utilizados para coleta de dados ou entrega de pequenos pacotes enfrentam limitações relacionadas à autonomia energética. A integração de WET a esses sistemas permite estender significativamente seu tempo de operação, eliminando a necessidade de paradas frequentes para recarga, o que potencializa aplicações como monitoramento ambiental e logística autônoma.[8]

Nesse contexto, o uso de técnicas de clusterização pode tornar essas aplicações ainda mais eficientes. Ao agrupar dispositivos IoT com base em critérios como localização geográfica, consumo energético e criticidade da aplicação, torna-se possível alocar os PBs de maneira estratégica, priorizando regiões com maior densidade de sensores ou com maior demanda energética.

Essa abordagem contribui para a continuidade operacional dos dispositivos, melhora a cobertura de energia e reduz o número de zonas de recarga ineficiente. Assim, a combinação de WET com inteligência baseada em clusterização torna-se uma solução promissora para suprir as demandas energéticas em redes IoT heterogêneas e em expansão.

III. APRENDIZADO DE MÁQUINA

A área de ML (do inglês *Machine Learning*) concentra-se no desenvolvimento de algoritmos capazes de extrair padrões e construir modelos a partir de dados brutos, de modo que seu desempenho em tarefas específicas melhore progressivamente com a experiência acumulada. Em termos formais, “um programa de computador aprende com a experiência E em relação a alguma tarefa P e critério de desempenho Q se seu desempenho em P, medido por Q, melhora com a experiência E” [9]. Para tanto, técnicas de ML utilizam métodos estatísticos e de otimização para ajustar automaticamente parâmetros internos, buscando minimizar erros de predição ou classificação diante de novos dados. Dentre suas aplicações destacam-se sistemas de recomendação, análise preditiva, reconhecimento de fala e

visão computacional, evidenciando o caráter versátil e adaptativo desta área de pesquisa.

Especificamente, as técnicas de Aprendizado de Máquina podem ser agrupadas em três paradigmas principais: *Aprendizagem Supervisionada*, que utiliza conjuntos de dados rotulados para ajustar modelos; *Aprendizagem Não Supervisionada*, que busca descobrir padrões e estruturas em dados não rotulados; e *Aprendizagem por Reforço*, na qual agentes aprendem por meio de interações com o ambiente e feedback em forma de recompensas. Neste trabalho, concentraremos-nos na *Aprendizagem Não Supervisionada*, cujo procedimento será detalhado a seguir.

A. Aprendizagem Não Supervisionada

O Aprendizado Não Supervisionado busca descobrir estruturas ou padrões ocultos em conjuntos de dados não rotulados, sem o auxílio de respostas pré-definidas. Ao contrário do aprendizado supervisionado, aqui o modelo deve inferir a organização intrínseca dos dados por meio de técnicas como agrupamento (clustering), redução de dimensionalidade e detecção de anomalias. Clustering, por exemplo, segmenta o conjunto em grupos homogêneos com base em métricas de similaridade, enquanto métodos de redução de dimensionalidade (como PCA) projetam os dados em espaços de menores dimensões, mantendo a maior variação possível.

Segundo Géron [10], esses algoritmos são fundamentais em cenários onde não há rótulos disponíveis, como na segmentação de clientes, análise exploratória de grandes bases de dados e descoberta de tópicos em textos. Em especial, dentre as diversas abordagens não supervisionadas, as técnicas de clusterização destacam-se por sua capacidade de segmentar automaticamente os dados em grupos baseados em similaridade. No que segue, apresentamos as principais metodologias de clustering utilizadas neste trabalho, incluindo K-Means, DBSCAN e Clusterização Hierárquica Aglomerativa.

B. Técnicas de Clusterização

A clusterização é uma técnica que agrupa automaticamente dados com base em características similares. Em cenários de IoT com Transferência Massiva de Energia Sem Fio (mWET), essa abordagem permite identificar regiões de maior densidade de dispositivos, facilitando o posicionamento estratégico dos PBs. Neste trabalho, são aplicadas e comparadas três técnicas distintas: K-Means, DBSCAN e Clusterização Hierárquica Aglomerativa.

b.1. K-Means

K-means é uma técnica de clusterização amplamente utilizada para organizar dados em grupos com base em sua similaridade [11]. Um exemplo prático de aplicação ocorre no setor varejista, como em supermercados que coletam informações sobre o comportamento de compra de seus clientes incluindo frequência de visitas, valor médio gasto por compra e os tipos de produtos adquiridos com maior regularidade. Com esses dados, o algoritmo K-means pode ser utilizado para segmentar os consumidores em perfis semelhantes, permitindo à empresa adotar estratégias personalizadas de marketing, fidelização e otimização de estoque. O algoritmo K-means inicia sua execução escolhendo aleatoriamente pontos centrais denominados centroides. Em seguida, cada ponto de dado é atribuído ao centróide

mais próximo, formando assim grupos conhecidos como clusters. O objetivo do algoritmo é particionar o conjunto de dados de forma que os elementos com características semelhantes pertençam ao mesmo grupo, maximizando a coesão interna dos clusters e a separação entre eles.

O algoritmo K-Means visa particionar n amostras em k grupos distintos, minimizando a soma das distâncias quadradas entre os pontos e seus respectivos centróides. A função objetivo a ser minimizada é:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (1)$$

Algorithm 1 Pseudocódigo do Algoritmo de agrupamento K-Means

1. Inicializar centróides:

- Aleatoriamente selecionar k pontos de dados do conjunto X como centróides iniciais.

2. Repetir até convergência:

(a) **Etapa de atribuição:**

- Para cada ponto de dado $x_i \in X$, calcule $\|x_i - \mu_j\|$ para todos os centróides μ_j .
- Atribua x_i ao centróide mais próximo.

(b) **Etapa de atualização:**

- Para cada centróide μ_j , recalcule

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i,$$

onde C_j é o conjunto de pontos atribuídos a μ_j .

3. Critérios de convergência:

- Verificar se os centróides pararam de se mover (mudança abaixo de um limiar ε).
 - Se convergiram, encerrar o algoritmo.
 - Caso contrário, voltar ao passo 2.
-

b.2. K-Means++

Além da inicialização aleatória padrão, tem-se também a estratégia *K-Means++* [12], na qual o primeiro centróide é escolhido aleatoriamente e cada centróide subsequente é amostrado com probabilidade proporcional ao quadrado de sua distância mínima a qualquer centróide já selecionado. Essa abordagem tende a espalhar melhor os centróides iniciais, reduzindo o número de iterações até a convergência e a variância dos resultados finais, além de, em média, melhorar métricas de qualidade do agrupamento (por exemplo, índice de silhueta e soma de quadrados intra-cluster). Entretanto, impõe um leve aumento de custo computacional na fase de inicialização, pois exige o cálculo adicional de distâncias e a amostragem ponderada, o

que pode demandar otimizações suplementares em cenários de grandes volumes de dados ou de alta dimensionalidade.

Algorithm 2 Pseudocódigo do K-Means++

- Entrada:** Conjunto de dados $X = \{x_1, \dots, x_n\}$, número de clusters K .

2. Inicialização do primeiro centróide:

- Escolha aleatoriamente um ponto $\mu_1 \in X$ como primeiro centróide.

3. Para $j = 2$ até K faça:

- Para cada ponto $x_i \in X$, calcule

$$D(x_i) = \min_{1 \leq r < j} \|x_i - \mu_r\|^2$$

(distância quadrática até o centróide mais próximo já escolhido).

- Calcule a soma total das distâncias:

$$S = \sum_{i=1}^n D(x_i).$$

- Para cada ponto x_i , defina a probabilidade de seleção como

$$P(x_i) = \frac{D(x_i)}{S}.$$

- Selecione aleatoriamente o próximo centróide μ_j a partir de X , de modo que

$$\Pr(\mu_j = x_i) = P(x_i).$$

4. Saída: Conjunto de centróides iniciais $\{\mu_1, \mu_2, \dots, \mu_K\}$.

b.3. DBSCAN

O algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise) é uma técnica de clusterização baseada em densidade, amplamente utilizada para identificar grupos de dados com alta concentração de pontos, mesmo em distribuições com formatos arbitrários. Diferente de algoritmos como o K-means, que assume a existência de clusters esféricos e exige a definição prévia do número de grupos, o DBSCAN não necessita dessa informação e é capaz de detectar automaticamente tanto os agrupamentos quanto os pontos considerados ruído (outliers) [13].

Seu funcionamento se baseia em dois parâmetros principais: o raio de vizinhança ε e o número mínimo de pontos *minPts*, que representa o número mínimo de pontos necessários dentro desse raio para formar um cluster denso. Um exemplo prático da aplicação do algoritmo DBSCAN ocorre no monitoramento de aglomerações urbanas. Suponha que uma prefeitura utilize dados de localização de dispositivos móveis para identificar a formação de grupos em espaços públicos, como praças ou eventos ao ar livre. O DBSCAN pode ser aplicado para de-

teectar automaticamente essas aglomerações com base em dois parâmetros: o raio de proximidade ε (por exemplo, 5 metros) e o número mínimo de pessoas próximas (*minPts*, como 10 pessoas) para formar um agrupamento.

A condição matemática para que um ponto seja considerado ponto central de um cluster é:

$$|\{x_j \in D \mid \|x_j - x_i\| \leq \varepsilon\}| \geq \text{minPts} \quad (2)$$

Algorithm 3 Pseudocódigo do Algoritmo DBSCAN

1. Inicialização:

- Marcar todos os pontos de D como *Unclassified*.
- $\text{clusterId} \leftarrow 1$.

2. Processamento de cada ponto:

- (a) Para cada ponto $p \in D$:
 - Se p está *Unclassified*, então:
 - i. $\text{Neighbors} \leftarrow \{q \in D \mid \text{dist}(p, q) \leq \varepsilon\}$.
 - ii. Se $|\text{Neighbors}| < \text{MinPts}$, rotular p como *Noise*.
 - iii. Senão:
 - Rotular todos $q \in \text{Neighbors}$ com clusterId .
 - Remover p de Neighbors .
 - Para cada $q \in \text{Neighbors}$:
 - A. $\text{Neighbors}_q \leftarrow \{r \in D \mid \text{dist}(q, r) \leq \varepsilon\}$.
 - B. Se $|\text{Neighbors}_q| \geq \text{MinPts}$, então $\text{Neighbors} \leftarrow \text{Neighbors} \cup \text{Neighbors}_q$.
 - C. Se q está *Unclassified* ou *Noise*, rotular q com clusterId .
 - iv. Incrementar $\text{clusterId} \leftarrow \text{clusterId} + 1$.

3. Saída:

- Conjunto de clusters rotulados e pontos finais de *Noise*.
-

O DBSCAN detecta clusters com formas arbitrárias, não requer definição prévia do número de grupos e identifica ruídos (outliers) de forma natural; porém, seu desempenho é sensível à escolha dos parâmetros ε e *minPts*, e sua eficiência tende a diminuir em bases de dados muito grandes ou com distribuições de densidade heterogêneas.

b.4. Clusterização Hierárquica Aglomerativa

A clusterização hierárquica aglomerativa é uma abordagem de agrupamento do tipo bottom-up, na qual cada ponto de dado inicia como um cluster individual [14]. Em cada iteração, os dois clusters mais semelhantes são combinados com base em

uma medida de proximidade, até que todos os pontos pertençam a um único grupo ou até que um critério de parada seja atendido. A decisão de fusão é baseada em uma métrica de distância, como:

- **Single linkage:** $\min \|x_i - x_j\|$
- **Complete linkage:** $\max \|x_i - x_j\|$
- **Average linkage:** média das distâncias entre pares de pontos

Esse processo é geralmente representado por um dendrograma, estrutura em forma de árvore que ilustra a sequência de fusões entre os clusters. Um exemplo prático da aplicação da clusterização hierárquica aglomerativa pode ser observado em uma biblioteca que deseja organizar seus livros com base na similaridade temática. Suponha que, com base em palavras-chave, categorias e frequência de empréstimos simultâneos, a biblioteca aplique o algoritmo para agrupar livros que costumam ser lidos juntos. Cada livro começa como um cluster individual, e, com base em suas semelhanças, os livros são gradualmente agrupados em categorias maiores: por exemplo, romances históricos se agrupam com biografias, e livros técnicos de eletrônica se aproximam dos de computação.

O dendrograma resultante permite à equipe visualizar diferentes níveis de agrupamento e decidir, por exemplo, como reorganizar fisicamente os livros nas estantes para facilitar a navegação dos leitores ou recomendar leituras complementares.

Algorithm 4 Pseudocódigo do Algoritmo Hierárquico Aglomerativo

- 1. Inicialização:** Cada ponto de dado forma um cluster separado.
 - 2. Repetir até convergência:**
 - (a) Calcular a distância entre todos os pares de clusters.
 - (b) Mesclar o par de clusters mais próximos em um único cluster.
 - 3. Critério de parada:** Pare quando restarem k clusters ou quando a menor distância entre pares exceder um limiar τ .
 - 4. Saída:** Conjunto de clusters finais (e, opcionalmente, o histórico de fusões para gerar o dendrograma).
-

A clusterização hierárquica aglomerativa não exige definição prévia do número de grupos, pois estes podem ser extraídos diretamente do dendrograma, e apresenta flexibilidade para agrupar estruturas de formatos variados; entretanto, esse método sofre alto custo computacional em conjuntos de dados extensos e revela sensibilidade a ruídos e outliers, que podem distorcer a hierarquia de fusões. Para ilustrar o processo de fusão progressiva dos sensores IoT e destacar os agrupamentos obtidos, recomenda-se a construção de um dendrograma com o corte apropriado que indique claramente os clusters finais.




Fig. 2. Modelo de Sistema.

IV. MODELO DO SISTEMA PROPOSTO

O presente tem como objetivo otimizar o posicionamento de PBs móveis visando maximizar a energia total coletada pelos dispositivos IoT. Portanto, para gerar a base de dados utilizada e para avaliar os resultados obtidos foi considerado o modelo de sistema ilustrado na Figura 2, onde um PB móvel equipado com um Arranjo Linear de Antenas (ULA, do inglês *Uniform Linear Array*) com N antenas é responsável por recarregar K dispositivos IoT equipados com uma antena. Além disso, nesse trabalho consideramos a arquitetura de *beamforming* analógico, a qual apresenta baixa complexidade de *hardware*, consumo de energia e custo quando comparada com as arquiteturas digital e híbrida [15, 16]. Logo, a arquitetura de *beamforming* analógico representa uma solução atrativa para sistemas WET práticos. Por fim, ignorando a potência do ruído, o sinal recebido no k -ésimo dispositivo IoT é dado por [17]

$$y_k = \sqrt{\beta_k} \Psi_k \mathbf{h}_k^H s, \quad (3)$$

em que $\Psi_k \in \mathbb{C}^{1 \times N}$ é o vetor de *beamforming* analógico no PB computado a partir da técnica *Equal Gain Combining* (EGC) onde $\|\Psi_k\|^2 = P_T$ e P_T denota a potência transmitida no PB, e s é o sinal transmitido. Além disso, $\beta_k = \frac{\lambda^2}{16\pi^2} d_k^{-\alpha}$ é o ganho de potência do canal entre o PB e o k -ésimo dispositivo IoT e $\lambda = \frac{c}{f}$ é o comprimento da onda, c é a velocidade da luz, f é a frequência da onda portadora, α é o expoente de perda de percurso e $d_k = \sqrt{(x_k - x_{PB})^2 + (y_k - y_{PB})^2 + (z_k - z_{PB})^2}$ denota a distância entre o PB e o k -ésimo dispositivo IoT em que (x_k, y_k, z_k) e (x_{PB}, y_{PB}, z_{PB}) denotam a posição do k -ésimo dispositivo IoT e do PB, respectivamente. Finalmente, $\mathbf{h}_k \in \mathbb{C}^{1 \times N}$ é o vetor de canal entre o PB e k -ésimo dispositivo IoT e é modelado considerando a distribuição Rice com fator rice (κ) igual para todos os canais [17, 18].

Baseado no modelo acima, a potência de RF recebida no k -ésimo dispositivo IoT é dada por [17]

$$P_k = \beta_k |\Psi_k \mathbf{h}_k^H|^2. \quad (4)$$

A energia coletada no k -ésimo dispositivo IoT é dada por [17]

$$E_k = \tau_k \gamma_k P_k, \quad (5)$$

em que τ_k denota o tempo de carregamento do k -ésimo dispositivo e γ_k denota a eficiência de conversão de energia no receptor do k -ésimo dispositivo IoT. Neste trabalho, por questões de simplicidade, consideramos que todos os dispositivos IoT possuem a mesma eficiência de conversão de energia, portanto, $\gamma = \gamma_k \forall K$. Portanto, através do modelo previamente descrito pode-se verificar que a energia coletada nos dispositivos IoT depende da posição do PB (x_{PB}, y_{PB}, z_{PB}), o que representa um desafio quando consideramos PBs móveis. Portanto, na próxima seção será apresentada a solução proposta para mitigar esse problema.

V. SOLUÇÃO PROPOSTA

A abordagem adotada neste trabalho consiste em um fluxo de processamento que combina modelagem de canal WET, engenharia de atributos e técnicas de clusterização para, ao fim, sugerir pontos ótimos de posicionamento de Power Beacons (PBs) em ambientes IoT densos. O pipeline divide-se em seis etapas:

A. 1. Geração e Modelagem de Canal

Utilizamos o modelo de Transferência de Energia sem Fio (WET) para gerar o vetor ϕ_s de cada dispositivo. Esse atributo quantifica a energia mínima coletada e incorpora variáveis como fator de Rice, perda de percurso e beamforming.

B. 2. Coleta de Dados Sintéticos

Simula-se um cenário bidimensional com $K = 20$ dispositivos IoT distribuídos aleatoriamente. Cada ponto contém coordenadas espaciais (x, y) . Esses dados compõem o DataFrame de entrada.

C. 3. Pré-processamento e Engenharia de Atributos

Para garantir comparabilidade entre variáveis, aplicamos `StandardScaler` a nas colunas:

$$\{x, y, \},$$

onde `dist_pb` é a distância Euclidiana até um PB de referência. Isso evita que escalas discrepantes distorçam os agrupamentos.

D. 4. Clusterização

Empregamos três algoritmos:

- **K-Means** ($k = 3$);
- **DBSCAN** ($\varepsilon = 0,5$, $\min_samples = 2$);
- **Agglomerativo (Ward)** ($k = 3$).

Cada técnica segmenta dispositivos em clusters de alta coesão, avaliados pelo Silhouette Score.

E. 5. Avaliação e Otimização

Nesta etapa, avaliamos a qualidade de separação dos clusters e o impacto energético de cada algoritmo por meio de duas métricas complementares: o índice de Silhouette, que mede a coesão interna e a separação externa dos grupos, e a soma total de ϕ_s , que reflete a eficiência agregada de transferência de energia. Para os métodos centróides—K-Means e Ward—fixamos $k = 3$ com base na distribuição espacial e energética esperada dos dispositivos. No caso do DBSCAN, ajustamos empiricamente os

parâmetros ε e min_samples de forma a obter entre dois e quatro clusters de tamanho equilibrado, sem recorrer ao método do cotovelo. A comparação conjunta do Silhouette Score e do ganho relativo em ϕ_s permitiu identificar a técnica que melhor equilibra a coerência dos agrupamentos e a maximização da energia coletada, orientando a seleção do modelo final para posicionamento dos Power Beacons.

F. 6. Definição de Posições de PBs

Por fim, para cada cluster $\mathcal{C}_i$, calcula-se o centróide geométrico em $(\bar{x}_i, \bar{y}_i)$ e sugere-se alocar um PB em cada $\bar{C}_i$. Essa estratégia garante cobertura equilibrada e maximiza a eficiência energética medida pelo modelo WET.

Assim, integrando a saída dos algoritmos de clusterização ao modelo de energia sem fio, obtemos um conjunto de posições de PBs que minimizam as distâncias e maximizam a energia coletada, cumprindo o objetivo de um posicionamento robusto em redes IoT de alta densidade.

VI. RESULTADOS

A modelagem baseou-se na aplicação de três técnicas de clusterização amplamente utilizadas: **K-Means**, **DBSCAN** e **Agrupamento Hierárquico**. Cada uma delas foi aplicada ao conjunto de dados normalizado, composto pelas coordenadas (x, y) e pelo consumo energético dos dispositivos IoT.

O **K-Means** foi executado com $k = 3$, valor definido com base em análises preliminares do conjunto de dados. Esse algoritmo buscou particionar os pontos em três agrupamentos, minimizando a distância euclidiana entre os pontos e seus centróides. A Figura 3 apresenta a distribuição espacial resultante, revelando agrupamentos com divisões bem definidas, ainda que limitadas à suposição de clusters esféricos e de tamanho similar.




Fig. 3. Clusters gerados pelo algoritmo K-Means

A. DBSCAN

O DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) foi configurado empiricamente com $\varepsilon = 1,5$ e $\text{min_samples} = 2$, sem recorrer ao método do cotovelo. Diferentemente do K-Means e da clusterização aglomerativa

de Ward, que exigem a definição prévia de k , o DBSCAN identifica agrupamentos com base na densidade local dos pontos. Nesta parametrização, o algoritmo detectou quatro clusters principais (rótulos 0, 1, 2, 3) e classificou diversos pontos dispersos como ruído (rótulo -1), conforme ilustrado na Figura 4. Essa flexibilidade torna o DBSCAN particularmente adequado para captar subestruturas espaciais complexas e densas em cenários de dispositivos IoT com distribuição irregular.




Fig. 4. Clusters formados pelo algoritmo DBSCAN com ajuste de parâmetros

O método de **Clusterização Hierárquica Aglomerativa**, por sua vez, também foi configurado para formar três grupos, utilizando o critério de ligação do tipo *ward*. A Figura 5 apresenta os agrupamentos formados, e a Figura 6 exibe o dendrograma gerado com uma amostra de 10 dispositivos, útil para a visualização da estrutura hierárquica das conexões.




Fig. 5. Agrupamentos obtidos via clusterização hierárquica

Esse gráfico representa visualmente o processo de fusão dos clusters ao longo do algoritmo aglomerativo, permitindo identificar a estrutura hierárquica dos dados e sugerir o número ideal de agrupamentos com base na distância entre os nós da árvore.

Cortes horizontais no dendrograma ajudam a determinar quantos clusters naturais estão presentes, sendo uma ferramenta útil para análise exploratória e decisões semânticas sobre segmentação.




Fig. 6. Dendrograma da clusterização hierárquica com amostra de 10 dispositivos

A Tabela II apresenta os valores de **Silhouette Score** obtidos para cada técnica de clusterização. Essa métrica varia de -1 a 1 e avalia o quão bem cada ponto está posicionado dentro do seu cluster: valores próximos de 1 indicam que os pontos estão bem agrupados e distantes dos outros clusters, enquanto valores próximos de 0 indicam sobreposição entre grupos, e valores negativos sugerem má alocação.

TABELA II
SILHOUETTE SCORE OBTIDO PARA CADA ALGORITMO DE CLUSTERIZAÇÃO

Algoritmo	Silhouette Score
K-Means	0.430481
Hierárquico	0.376974
DBSCAN	0.752341

Os resultados obtidos foram:

- **K-Means:** 0,430481, scores entre 0,25 e 0,5 são considerados moderados. O K-Means força centróides globais e tende a criar clusters convexas de tamanho parecido, mas nem sempre respeita regiões de densidade desigual.
- **Hierárquico:** 0,376974, também na faixa moderada a baixa, a clusterização aglomerativa (linkage “ward”) gerou grupos menos bem definidos, refletindo talvez a sensibilidade a outliers e à forma esperada dos clusters. O fato de mesclar pontos passo a passo sem um critério de densidade pode levar a uniões prematuras de pontos distantes.
- **DBSCAN:** 0,752341, um valor acima de 0,7 indica clusters bem separados e internamente coesos. Como o DBSCAN agrupa com base em densidade, ele conseguiu isolar agrupamentos homogêneos de dispositivos, descartando como ruído pontos que não se encaixavam em regiões densas. Isso explica o alto grau de clareza na fronteira entre os grupos.

A Figura 7 ilustra essa comparação de forma gráfica, destacando a superioridade do DBSCAN em termos de coesão e separação entre grupos.




Fig. 7. Comparação do Silhouette Score entre os algoritmos

Esses resultados indicam que o DBSCAN, ao identificar regiões de alta densidade e descartar efetivamente pontos de ruído, produz partições mais coesas e maximiza a eficiência do carregamento sem fio em cenários IoT densos.

B. Comparação de Estratégias de Ordenação para WET

Para quantificar o impacto de diferentes políticas de ordenação dos dispositivos sobre a métrica ϕ_s (soma total de energia coletada), comparamos quatro cenários:

1. **Aleatório** (baseline): ordem de atendimento sem qualquer agrupamento;
2. **Hierárquico:** clusterização aglomerativa (linkage “ward”);
3. **K-Means:** clusterização em $K = 3$ grupos;
4. **DBSCAN:** clusterização baseada em densidade.

Conforme a Tabela III, o método hierárquico elevou a soma de ϕ_s em $\approx 45\%$ (em outras palavras, resultou em um valor $1,45\times$ maior que o baseline), enquanto o K-Means e o DBSCAN alcançaram fatores de $\approx 2,30\times$ e $\approx 2,45\times$, respectivamente.

TABELA III
SUMÁRIO DA SOMA TOTAL DE ϕ_s ($\times 10^6$) E SEU GANHO RELATIVO EM RELAÇÃO AO CENÁRIO ALEATÓRIO.

Método	$\sum \phi_s$ (10^6)	Ganho (%)	Fator
Aleatório (baseline)	3233	0	1,00×
Hierárquico	4680	45	1,45×
K-Means	7446	130	2,30×
DBSCAN	7933	145	2,45×

A clusterização baseada em densidade (DBSCAN) apresentou o maior ganho, quase $2,5\times$ o valor do baseline, indicando

que agrupar dispositivos em regiões de alta densidade antes do carregamento maximiza a energia total coletada. O K-Means obteve desempenho semelhante ($\approx 2,3\times$), reforçando a eficácia de centroides bem distribuídos. A abordagem hierárquica, embora menos intensa, ainda elevou ϕ_s em cerca de 45% em relação ao aleatório. Esses resultados evidenciam que todas as técnicas de clusterização superaram significativamente a estratégia sem agrupamento.

VII. CONCLUSÃO

Este trabalho apresentou um pipeline integrado que combina modelagem de canal WET e técnicas de clusterização para apoiar o posicionamento estratégico de PBs em redes densas de dispositivos IoT. Inicialmente, geramos o vetor energético ϕ_s para cada dispositivo, capturando os efeitos de beamforming analógico, fator de Rice e perda de percurso. Em seguida, aplicamos três métodos de agrupamento (K-Means, DBSCAN e Hierárquico) sobre o conjunto normalizado de atributos (x, y , consumo, ϕ_s , dist_pb), avaliando sua qualidade com o índice de Silhouette e seu impacto na soma total de ϕ_s .

Os experimentos mostraram ganhos expressivos em relação ao cenário aleatório: a clusterização hierárquica elevou ϕ_s em $1,45\times$, o K-Means alcançou $2,30\times$ e o DBSCAN atingiu $2,45\times$ (ver Tabela III). Observou-se também que o DBSCAN apresentou o maior Silhouette Score ($\approx 0,75$), indicando clusters bem separados e internamente coesos; o K-Means obteve valor intermediário ($\approx 0,43$) e a abordagem hierárquica registrou o menor escore ($\approx 0,38$). Esses resultados sugerem que, além de maximizar a energia coletada, o DBSCAN é capaz de gerar partições de alta qualidade, aproveitando regiões de densidade elevada para otimizar o carregamento.

Essa abordagem integrada apresenta diversos benefícios práticos e sociais. Ao aumentar a eficiência do carregamento sem fio, reduz-se a frequência de troca de baterias e de componentes eletrônicos, contribuindo para a redução de resíduos e mitigação de impactos ambientais. Sensores IoT passam a operar por períodos mais longos, viabilizando aplicações críticas em saúde, agricultura de precisão e monitoramento ambiental em áreas remotas sem manutenção constante. A estratégia de posicionamento e sequência de atendimento otimiza deslocamentos e tempo de operação dos PBs, tornando soluções de cidades inteligentes mais acessíveis e financeiramente viáveis. Além disso, comunidades isoladas ganham acesso confiável à energia de sensores, impulsionando iniciativas de desenvolvimento social e inovação local.

Para trabalhos futuros, sugere-se explorar heurísticas de otimização, como algoritmos genéticos ou programação matemática, para refinar automaticamente a escolha dos pontos de instalação de PBs considerando restrições práticas e custos operacionais; validar a solução em cenários reais de IoT, comparando simulações de ϕ_s com medições experimentais de energia coletada; introduzir variáveis temporais de consumo e mobilidade dos dispositivos para permitir ajustes adaptativos da alocação de PBs conforme padrões de uso diários e sazonais; e avaliar a escalabilidade da abordagem em áreas geográficas maiores e topologias de rede mais complexas, incluindo ambientes urbanos densos com múltiplos PBs cooperantes.

REFERÊNCIAS

- [1] Onel L. A. López, Hirley Alves, Richard Demo Souza, Samuel Montejó-Sánchez, Evelio Martín García Fernández e Matti Latva-Aho. “Massive Wireless Energy Transfer: Enabling Sustainable IoT Toward 6G Era”. Em: *IEEE Internet of Things Journal* 8.11 (2021), pp. 8816–8835. DOI: 10.1109/JIOT.2021.3050612.
- [2] McKinsey Global Institute. *Connected World: An evolution in connectivity beyond the 5G Revolution*. Rel. técn. Acesso em: 10 mar. 2025. McKinsey & Company, fev. de 2020. URL: https://www.mckinsey.com/~media/mckinsey/industries/technology%20media%20and%20telecommunications/telecommunications/our%20insights/connected%20world%20an%20evolution%20in%20connectivity%20beyond%20the%205g%20revolution/mgi_connected-world_discussion-paper_february-2020.pdf.
- [3] QoiTech Team. *The hidden cost of IoT: Why battery life must be a top priority*. 2024. URL: <https://www.goitech.com/blog/the-hidden-cost-of-iot-why-battery-life-must-be-a-top-priority/> (acesso em 20/10/2024).
- [4] Hamed Rahmani et al. “Next-Generation IoT Devices: Sustainable Eco-Friendly Manufacturing, Energy Harvesting, and Wireless Connectivity”. Em: *IEEE Journal of Microwaves* 3.1 (2023), pp. 237–255. DOI: 10.1109/JMW.2022.3228683.
- [5] J. Rosabal, J. Lopez e L. Onel. “Massive Wireless Energy Transfer with Multiple Power Beacons for Very Large Internet of Things”. Em: *Open Journal of Internet of Things (OJIOT)* 7.1 (2021). URL: https://www.ronpub.com/OJIOT_2021v7i1n08_Rosabal.pdf.
- [6] Suzhi Bi, Chin Keong Ho e Rui Zhang. “Wireless powered communication: opportunities and challenges”. Em: *IEEE Communications Magazine* 53.4 (2015), pp. 117–125. DOI: 10.1109/MCOM.2015.7081084.
- [7] Ayad Soheyb, Talli Abdelmoutia e Terrissa Sadek Labib. “Toward agriculture 4.0: Smart farming environment based on robotic and IoT”. Em: *2021 4th International Symposium on Advanced Electrical and Communication Technologies (ISAECT)*. 2021, pp. 1–5. DOI: 10.1109/ISAECT53699.2021.9668490.
- [8] Prithvi Chittoor, C. Bharatiraja e Lucian MIHET-POPA. “A Review on UAV Wireless Charging: Fundamentals, Applications, Charging Techniques and Standards”. Em: *IEEE Access* PP (mai. de 2021), pp. 1–1. DOI: 10.1109/ACCESS.2021.3077041.
- [9] T. Mitchell. *Machine Learning*. 1nd. McGraw-Hill Science, 1997. ISBN: 0070428077.

- [10] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 2nd. O'Reilly Media, 2019. ISBN: 9781492032649.
- [11] Akanksha Kapoor e Abhishek Singhal. "A comparative study of K-Means, K-Means++ and Fuzzy C-Means clustering algorithms". Em: *2017 3rd International Conference on Computational Intelligence Communication Technology (CICIT)*. 2017, pp. 1–6. DOI: 10.1109/CICT.2017.7977272.
- [12] David Arthur e Sergei Vassilvitskii. "k-means++: The Advantages of Careful Seeding". Em: *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*. New Orleans, LA, USA: SIAM, 2007, pp. 1027–1035.
- [13] Dingsheng Deng. "DBSCAN Clustering Algorithm Based on Density". Em: *2020 7th International Forum on Electrical Engineering and Automation (IFEEA)*. 2020, pp. 949–953. DOI: 10.1109/IFEEA51475.2020.00199.
- [14] F. Murtagh. "A Survey of Recent Advances in Hierarchical Clustering Algorithms". Em: *The Computer Journal* 26.4 (nov. de 1983), pp. 354–359. ISSN: 0010-4620. DOI: 10.1093/comjnl/26.4.354. eprint: <https://academic.oup.com/comjnl/article-pdf/26/4/354/1072603/26-4-354.pdf>. URL: <https://doi.org/10.1093/comjnl/26.4.354>.
- [15] Xiaopeng Yuan, Hao Jiang, Yulin Hu e Anke Schmeink. "Joint Analog Beamforming and Trajectory Planning for Energy-Efficient UAV-Enabled Nonlinear Wireless Power Transfer". Em: *IEEE Journal on Selected Areas in Communications* 40.10 (2022), pp. 2914–2929. DOI: 10.1109/JSAC.2022.3196108.
- [16] Shengli Zhang, Chongtao Guo, Taotao Wang e Wei Zhang. "ON-OFF Analog Beamforming for Massive MIMO". Em: *IEEE Transactions on Vehicular Technology* 67.5 (2018), pp. 4113–4123. DOI: 10.1109/TVT.2018.2789661.
- [17] Victoria Dala Pegorara Souto, Osmel Martínez Rosabal, Samuel Montejo-Sánchez, Onel Luis Alcaraz López, Hirley Alves e Richard Demo Souza. "An Analog Beamforming Strategy Based on Statistical Channel Information for Recharging Wireless Powered Sensor Networks". Em: *IEEE Sensors Journal* 24.14 (2024), pp. 23025–23033. DOI: 10.1109/JSEN.2024.3405854.
- [18] Elena Boshkovska, Derrick Wing Kwan Ng, Nikola Zlatanov e Robert Schober. "Practical Non-Linear Energy Harvesting Model and Resource Allocation for SWIPT Systems". Em: *IEEE Communications Letters* 19.12 (2015), pp. 2082–2085. DOI: 10.1109/LCOMM.2015.2478460.



Ana Cecília Silveira Fernandes é graduada em Engenharia de Computação pelo Instituto Nacional de Telecomunicações (INATEL) e atualmente cursa o mestrado em Telecomunicações pela mesma instituição, com previsão de conclusão em 2027. Atuou como estagiária de desenvolvimento *Full-Stack* no INATEL, onde participou da criação de soluções interativas e responsivas, com foco em *frontend*, *backend*, APIs e testes, visando a melhoria da experiência do usuário. Possui vivência em projetos acadêmicos e práticos nas áreas de desenvolvimento de aplicativos móveis e inteligência artificial. Seus principais interesses incluem Engenharia de Software, Inteligência Artificial, Ciência de Dados e Machine Learning.



Pedro Guilherme Fernandes Oliveira possui formação técnica em Eletrônica com ênfase em Automação Industrial pela Escola Técnica de Eletrônica "Francisco Moreira da Costa" (ETE FMC). Atualmente, é graduando em Engenharia de Software e aluno especial do programa de mestrado do Inatel. Atua como estagiário no Inatel Competence Center, na área de treinamento e educação continuada. Seus interesses incluem

Pesquisa e Desenvolvimento de Software, Visão Computacional e Inteligência Artificial.